

内閣府景気動向指数の先行系列に基づく 機械学習を用いた短期経済予測

Japanese Economic forecasting model based on
the Cabinet Office's Indexes of Business Conditions

水門善之^{1,2*} 坂地泰紀¹

和泉潔¹ 島田尚¹ 松島裕康¹

Yoshiyuki Suimon^{1,2} Hiroki Sakaji¹

Kiyoshi Izumi¹ Takashi Shimada¹ Hiroyasu Matsushima¹

¹ 東京大学大学院工学系研究科システム創成学専攻

¹ Department of Systems Innovations, School of Engineering
The University of Tokyo

² 野村證券株式会社金融経済研究所経済調査部

² Economic Research Department, Financial and Economic Research Center
Nomura Securities Co., Ltd.,

Abstract: 企業や家計などの経済主体の活動は、様々なメカニズムにより、相互に影響を与えていく。そのため、先行的な活動をとらえた経済統計には、先行きの経済の動きを示唆する情報が含まれると考えられる。本研究では、内閣府景気動向指数の先行指数の算出に採用される 11 の先行系列を用いて、各種機械学習手法を用いた短期経済予測モデルを構築し、その予測特性の検証を行った。その結果、ディープラーニング手法の一種であり再帰的なネットワーク構造を持つ RNN（リカレントネットワークニューラルネットワーク）において、相対的に高い予測精度が確認できた。また、RNN ベースの予測モデルの構築の際、景気動向指数の先行指数のみを学習に用いた場合に比べて、先行系列 11 系列を学習に用いた場合、先行きの経済予測の精度に改善の傾向が見られた。このことは、経済的に先行性を持つと解釈される複数の系列の情報を、RNN を用いて直接モデル化することで、先行きの経済予測に関して有用な情報の抽出が可能となることを示唆する結果と言えよう。

はじめに

景気とは、企業や家計などの主要な経済主体の活動の状況であり、各主体の活動は、様々なメカニズムにより、相互に影響を与えていく。本研究では、先行的な動きをする経済主体の動向を捉えた統計情報を用いることで、先行きの経済予測を試みる。具体的には、内閣府が毎月公表している景気動向指数の先行指数に着目し、その算出に用いられる 11 の先行系列を用いて、ニューラルネットワークをベースとした機械学習手法（MLP, RNN, LSTM）に基づく短期経済予測モデルを構築する。更に、その予測特性についての検証をおこなう。

経済のメカニズム

経済全体を構成する企業や家計といった様々な主体は、相互に影響を与えながら、日々経済活動を行っている。例えば、企業の好調は、更なる生産活動の拡大に向けた設備投資をうながす。また生産活動の活発化は、労働需要を高めることから、賃金の上昇圧力となる。更に、家計所得の増加は消費支出の増加をもたらす。結果、更なる生産活動の活発化につながっていく。このような、様々な経済の波及メカニズムをフローチャートとして表したのが、[1]による図 1 だ。ここでは、実体経済において、生産が雇用・所得を決定し、所得によって需要が左右され、

* Email: d2018ysuimon@socsim.org

更に需要が生産を決定するという、「生産⇒雇用・所得⇒支出（需要）⇒生産」の経済のメカニズムが示されている。

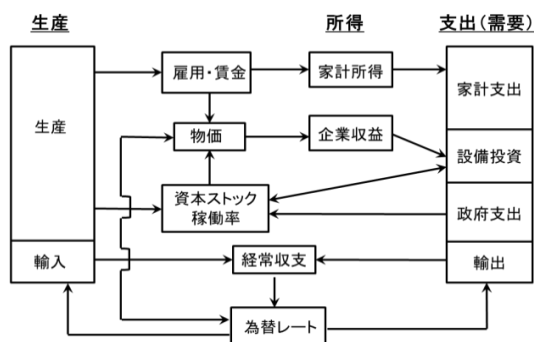


図 1: 景気循環のフローチャート

このような実体経済の流れは、様々な経済統計を観測することで把握することができます。また内閣府は、景気の現状把握及び将来予測のため、生産、雇用といった様々な経済活動において、重要かつ景気に敏感に反応する指標の動きを統合した、景気動向指数を公表している[2]。

内閣府景気動向指数

景気動向指数には、コンポジット・インデックス（CI）とディフュージョン・インデックス（DI）がある。CIとは、構成する各指標の前月からの変化を合成した指数であり、景気変動の大きさやテンポが把握できる。DIとは、構成する各指標の各月の値を3ヶ月前と比べた変化方向を合成した指数であり、変化方向がプラスとなる系列数の割合を示したものである。




図 2: 内閣府景気動向指数

CI と DI には、それぞれ、景気に対し先行して動く先行指数、ほぼ一致して動く一致指数、遅れて動く遅行指数の3つの指数がある。一致指数は景気の現状把握に利用することができ、先行指数は、一致

指数に数か月程度先行する傾向があることから、景気の予測を目的として利用される。遅行指数は、一致指数に数か月から半年程度遅行する傾向があることから、事後的な景気の確認に用いられる。図2に、CIベースの、先行指数、一致指数、遅行指数を掲載した。各指標の先行遅行関係が確認できよう。

本研究ではCIに着目するが、CIとDIは共通の基礎統計を参照しており、現在、指標の作成に用いられている系列は表1、2、3に示した通りである。CIの算出には、各採用系列の、前月と当月の平均値を分母とした際の当月にかけての変化率（対称変化率）を求め、各系列の対称変化率を合成したものが、CIの変化率のベースとなる。指数の作成方法の詳細は[2]を参照されたい、

表 1: 景気動向指数の先行系列

先行系列名	基礎統計出所
L1 最終需要財在庫率指数	経済産業省
L2 鉱工業用生産財在庫率指数	経済産業省
L3 新規求人数(除学卒)	厚生労働省
L4 実質機械受注(製造業)	内閣府、日本銀行
L5 新設住宅着工床面積	国土交通省
L6 消費者態度指数	内閣府
L7 日経商品指数(42種)	日本経済新聞社
L8 マネーストック(M2)	日本銀行
L9 東証株価指数	東京証券取引所
L10 投資環境指数(製造業)	財務省、日本相互証券
L11 中小企業売上げ見通LDI	日本政策金融公庫

表 2: 景気動向指数の一致系列

一致系列名	基礎統計出所
C1 生産指数(鉱工業)	経済産業省
C2 鉱工業用生産財出荷指数	経済産業省
C3 耐久消費財出荷指数	経済産業省
C4 所定外労働時間指数(調査産業計)	厚生労働省
C5 投資財出荷指数(除輸送機械)	経済産業省
C6 商業販売額(小売業)(前年同月比)	経済産業省
C7 商業販売額(卸売業)(前年同月比)	経済産業省
C8 営業利益(全産業)	財務省
C9 有効求人倍率(除学卒)	厚生労働省

表 3: 景気動向指数の遅行系列

遅行系列名	基礎統計出所
Lg1 第3次産業活動指数(対事業所サービス業)	経済産業省
Lg2 常用雇用指数(調査産業計)	厚生労働省
Lg3 実質法人企業設備投資(全産業)	財務省、内閣府
Lg4 家計消費支出(勤労者世帯)	総務省
Lg5 法人税収入	財務省
Lg6 完全失業率	総務省
Lg7 きまって支給する給与(製造業、名目)	厚生労働省
Lg8 消費者物価指数(生鮮食品を除く総合)	総務省
Lg9 最終需要財在庫指数	経済産業省

機械学習を用いた短期経済予測

前述の通り、景気動向指数の先行指数は、一致指数に数か月程度先行する傾向があることから、経済の先行きを見通すうえでは有用な指標であると言える。

景気動向指数の先行指数を用いた景気の先行き予測のプロセスは、図3の通りである。景気動向指数の先行指数は、11個の基礎統計を合成して作成されることから、統合的に景気の動きが把握できるというメリットがある一方、基礎統計を合成する際に個別の系列が持つ変動情報が失われてしまうという面もある。この点を踏まえ、本研究では、11系列の基礎統計の情報を予測に活用するために、各系列の変動データを、直接的に、予測モデルの学習に用いることで、先行きの一致指数の予測精度の向上を試みる。




図3: 従来の景気の先行き予測プロセス

図4に景気動向指数の先行指数の基礎統計である11の先行系列の月次変化を掲載した。ここではCIの算出の際に用いる対称変化率ベースの値を示している。本稿では、これらのデータを用いて一致指数の先行きを予測する。具体的には、11個の先行系列の、過去12カ月間の動きをインプットデータ、一致指数の先行きの動き(1カ月後, 2カ月後, 3カ月後)をラベルデータとして、機械学習モデルの構築を行う。

特に、11個の先行系列が示す景気の変化が、その後の実体経済に波及していく過程においては、系列

によって時間差などにばらつきがあると考えられる。そのため、本研究では、各統計の過去12カ月分の変化の情報を用いることで、先行きの景気の変化に対する過去に観測された予兆の情報を捕捉したい。




図4: 提案モデルの学習データ

予測モデルの構築

本研究では、景気動向指数の先行指数の基礎統計11系列及び先行指数、一致指数の、1985年から2018年までの月次データを対象に分析を行った。予測モデル構築の際に用いた機械学習手法は、MLP(多層パーセプトロン)、RNN(リカレントニューラルネットワーク)、LSTM(ロングショートタームメモリ)であり、比較対象として、線形の重回帰に基づく予測モデルも構築した。

MLPの場合は、図5に示したネットワーク図にあるように、11系列の過去12か月分にあたる132個の値をインプットデータとし、先行きの一致指数の月次変化をラベルデータとした。出力層に対応させる先行きの一致指数は、1~2カ月後, 2~3カ月後, 3~4カ月後の各変化とした。線形の重回帰の場合は、

11 系列の過去 12 か月分の 132 系列を説明変数とし、先行きの一致指数の月次変化を被説明変数とした。




図 5: MLP のネットワーク図

また、RNN を用いたモデルの実装も行った。RNN とは、図 6 に示すように、リカレント（再帰）な特性を持つニューラルネットワークであり、入力層と出力層の間にある隠れ層が、再帰的なネットワークとして結合されているものである。加えて、LSTM（隠れ層におけるノードが、LSTM ブロックと呼ばれる構造を持つモデル[3][4]）を用いた実装も、併せて行った。これらのモデルでは、過去 12 か月分の 11 系列の変化を、1 か月分ごとにネットワークに入力していき、出力層に対応させるデータは、MLP の場合と同様に、一致指数の 1~2 か月後、2~3 か月後、3~4 か月後の各変化とした。

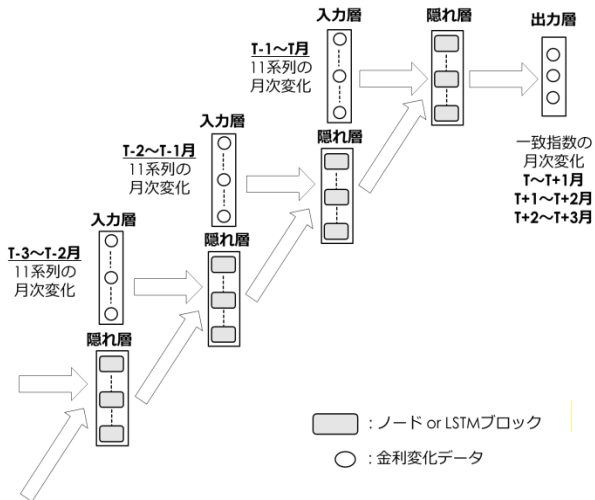


図 6: RNN/LSTM のネットワーク図

更に、学習におけるインプットデータとして、先行系列 11 系列を用いた場合と、統合された先行指数 1 系列のみを用いた場合とで、予測精度に生じる違いの検証も行う。その際、RNN 及び重回帰モデルでは、先行指数 1 系列の過去 12 か月分にあたる 12 個の値をインプットデータとして、モデルの学習を行う。また、RNN 及び LSTM では、過去 12 か月分の先行指数 1 系列の変化を、1 か月分ごとにネットワークに入力することでモデルの学習を行う。

なお、本研究で構築したこれらネットワークモデ

ルのノード数や活性化関数については、表 4 にまとめた。

表 4: 各機械学習モデルの構造リスト

表記	モデル	モデル構造
LinRe	線形回帰(重回帰)	
MLP1	多層パーセプトロン	活性化関数: ハイバボリックタンジェント 各レイヤーのノード数 基礎統計11系列使用: 132-50-50-3 先行指数1系列使用: 12-6-6-3
MLP2	多層パーセプトロン	活性化関数: ハイバボリックタンジェント 各レイヤーのノード数 基礎統計11系列使用: 132-50-50-50-3 先行指数1系列使用: 12-6-6-6-3
RNN1	リカレントニューラルネットワーク	活性化関数: ハイバボリックタンジェント 隠れ層のノード数: 50
RNN2	リカレントニューラルネットワーク	活性化関数: ハイバボリックタンジェント 隠れ層のノード数: 100
RNN3	リカレントニューラルネットワーク	活性化関数: ハイバボリックタンジェント 隠れ層のノード数: 150
LSTM1	ロングショートタームメモリ	活性化関数: ハイバボリックタンジェント リカレント活性化関数: シグモイド LSTMブロックの数: 50
LSTM2	ロングショートタームメモリ	活性化関数: ハイバボリックタンジェント リカレント活性化関数: シグモイド LSTMブロックの数: 100
LSTM3	ロングショートタームメモリ	活性化関数: ハイバボリックタンジェント リカレント活性化関数: シグモイド LSTMブロックの数: 150

予測モデルの評価と検証

本章では、構築したモデルを用いて、景気動向指数の一致指数の先行き予測精度の検証を行う。なお、本研究では、1985 年から 2018 年までの期間を対象とした、連続する 15 か月分（インプットデータ 12 か月分とラベルデータ 3 か月分）を一まとまりとしたデータの集合の中から、ランダムに選んだ 8 割をモデルの学習データとして使い、残りの 2 割をテストデータとして予測精度の検証を行った。更に、同様の試行を 5 回行い、5 種類のテストデータを用いて、モデルの精度検証を行った。

図 7-9 にテストデータ 1 を用いた結果を掲載した（テストデータ 2-5 を対象とした結果については、巻末の Appendix の図 10-17 に掲載）。ここでは、表 4 に示した各手法に基づく、景気動向指数の一致指数の 1, 2, 3 か月後の月次変化の予測精度を確認するため、予測値と実績値の平均二乗誤差（MSE）を図 7 に、両者の相関係数を図 8 に示した。更に、モデルの学習に、先行指数の基礎統計 11 系列を用いた場合と、先行指数 1 系列のみを用いた場合の結果も両図に併記した。これによると、今回検証した手法の中では、RNN の予測精度が相対的に高くなる傾向が見て取れる。また、RNN に基づくモデルの中でも、先行指数の基礎統計 11 系列をモデルの学習に用いた場合、先行指数 1 系列のみを学習に用いた場合に比べて、相対的に高い予測精度が確認できた。

図 7: MSE (テストデータ 1)


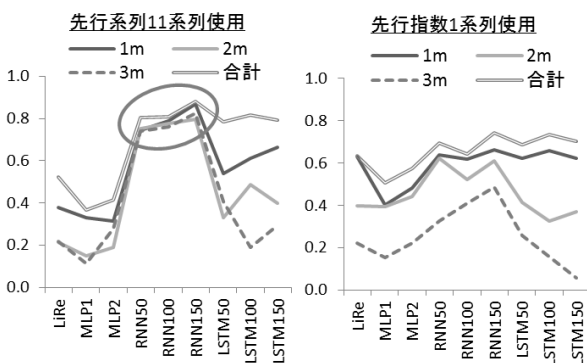



図 8: 相関係数 (テストデータ 1)



更に、図 8 には、先行き 1, 2, 3 カ月後の一致指数の月次変化の予測精度に加えて、1-3 カ月間の合計変化に対する予測精度も併せて掲載した。図中には、3 カ月分の単月の予測値の合計と、3 カ月分の実績の累積変化の相関係数を“合計”として掲載した。これによると、単月の予測に比べて、予測精度の向上が確認できよう。このことは、実績値にはモデルでは予測が難しい様々なノイズが含まれるが、実績値の変化を 3 カ月分合算させることで、例えば天候要因のような一時的な特殊要因であれば、悪天候月における消費の悪化と、翌月の回復が合わさることで、ノイズがキャンセルアウトされること等が影響していると考えられる。

今回の検証で特に予測精度の高かった RNN150 に基づく、一致指数の先行き 3 カ月分の変化の予測値の合計と、実績の変化の合計の関係を図 9 に掲載した。このように RNN を用いたモデルの予測精度が、LSTM に比べて高いのは、今回扱った経済統計が月次統計であり、扱うデータ量がある程度限られることから、再帰性を持つネットワークモデルにおいても、LSMT のような複雑なモデルに比べて、相対的にシンプルな RNN のほうが予測に適していると考えられる。

図 9: RNN150 に基づく 3 カ月変化の予測値とテストデータ



結論

本研究では、景気への先行性を持つ、景気動向指数の先行系列を構成する基礎統計 11 系列に着目し、ニューラルネットワークをベースとした各種機械学習手法を用いて、先行き 1 四半期の景気（景気動向指数の一致指数）を予測するモデルを構築した。その結果、再帰的なネットワーク構造を持つ RNN において、相対的に高い予測精度が確認できた。特に、先行指数 1 系列のみをモデルの学習に用いた場合に比べて、11 の先行系列を学習に用いた場合の、予測精度の向上が目立った。このことは、経済的に先行性を持つと解釈される複数の系列の情報を、直接 RNN に取り込むことで、先行きの経済予測に関して有用な情報の抽出が可能となることを示唆する結果と言えよう。

留意事項

本稿は、著者の個人見解を表すものであり、野村證券株式会社の公式見解を表すものではありません。

参考文献

- [1] 梅田雅信, 宇都宮浄人, “経済統計の活用と論点,” 2009 年 11 月, 東洋経済新報社
- [2] 内閣府, 景気動向指数
https://www.esri.cao.go.jp/jp/stat/di/menu_di.html
- [3] Sepp Hochreiter and Jürgen Schmidhuber, “Long Short-Term Memory, Neural Computation,” Vol.9, No.8, pp.1735-1780, 1997
- [4] Felix A. Gers, Jürgen Schmidhuber and Fred A. Cummins, “Learning to Forget: Continual Prediction with LSTM,” Neural Computation, Vol.12, No.10, pp.2451-2471, 2000

Appendix.




図 10: MSE (テストデータ 2)




図 14: MSE (テストデータ 4)

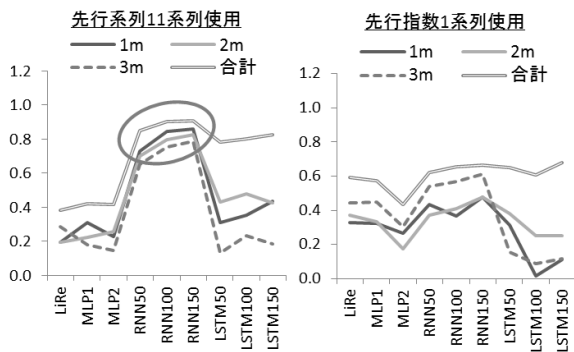


図 11: 相関係数(テストデータ 2)

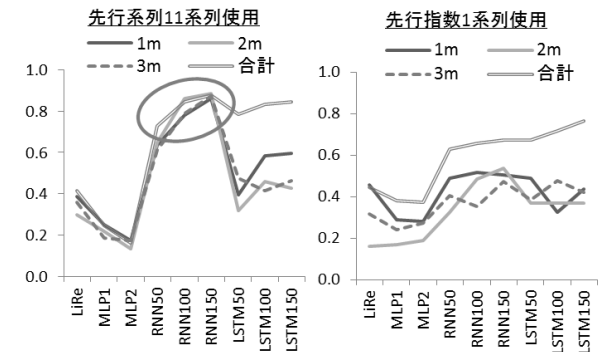


図 15: 相関係数(テストデータ 4)




図 12: MSE (テストデータ 3)

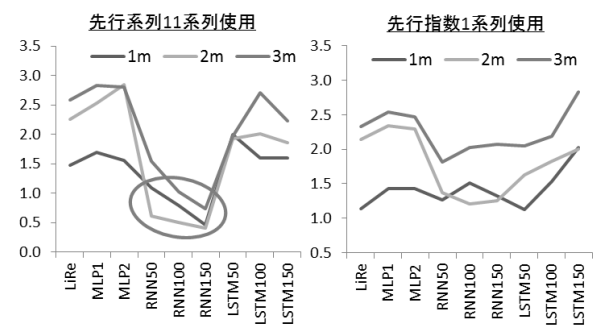


図 16: MSE (テストデータ 5)

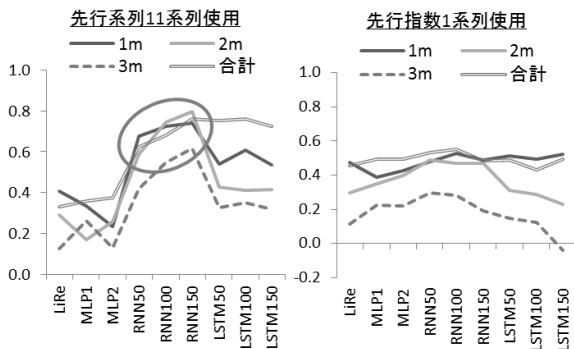


図 13: 相関係数(テストデータ 3)

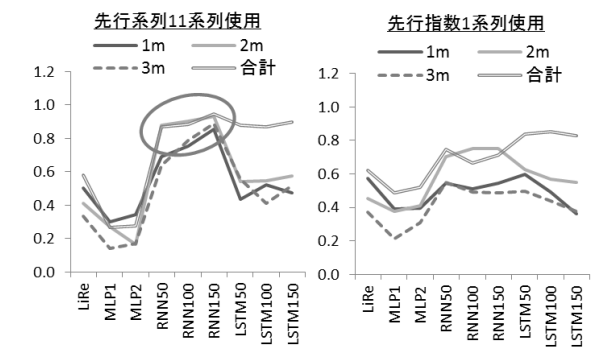


図 17: 相関係数(テストデータ 5)